

Отчет

Лабораторная работа № 5.2

Генерация текста с помощью RNN (символьный уровень)

1. Описание датасета (источник, размер, период)

Датасет представляет собой отрывок из романа “Война и мир” Л.Н. Толстого. Источник текста <https://ilibrary.ru/text/11/index.html>. Из текста предварительно были удалены пустые строки, символы тире, отступы.

Пример фрагмента загруженного текста и его характеристики:

Текст загружен из файла. Длина: 42369 символов

Первые 500 символов текста:

Ну что, князь, Генуя и Лукка стали не больше как поместья, поместья фамилии Буонапарте. Нет, я вам вперед говорю, если вы мне не скажете, что у нас война, если вы позволите себе защищать все гадости, все ужасы этого антихриста (право, я верю, что он антихрист), я вас больше не знаю, вы уже не друг мой, вы уже не мой верный раб, как вы говорите. Ну, здравствуйте, здравствуйте. Я вижу, что я вас пугаю, садитесь и рассказывайте. Так говорила в июле 1805 года известная Анна Павловна Шерер, фрейлина

2. Создание алфавита и кодирование текста

В ходе обработки был получен алфавит текста и созданы словари для кодирования и декодирования текста:

Размер алфавита: 77
Первые 20 символов алфавита:
!"(),-.014578:;?ao
Исходный текст: Привет, мир!
Закодированный: [34, 60, 52, 46, 49, 62, 6, 1, 56, 52, 60, 2]
Декодированный: Привет, мир!

3. Формирование последовательностей для обучения

С целью дальнейшего обучения были получены обучающие последовательности. Характеристики обучающих последовательностей:

Длина последовательности: 100
X shape: (42269, 100), y shape: (42269,)
Пример входа (первые 10 индексов): [32 63 1 67 62 58 6 1 54 57]
Пример цели: 59 -> символ 'п'
Количество батчей: 331

4. Определение модели LSTM

Была разработана модель нейросети на основе LSTM:

```
self.embedding = nn.Embedding(vocab_size, embed_size)
```

```
self.lstm = nn.LSTM(embed_size, hidden_size, num_layers, batch_first=True)
self.fc = nn.Linear(hidden_size, vocab_size)
```


Параметры модели:

Количество параметров: 951,245
Размер встраивания: 128
Скрытый размер: 256
Количество слоёв: 2 (LSTM)

5. Обучение и график потерь с комментариями о сходимости.

Начало обучения...

Эпоха 5/35, Потери: 1.5438
Эпоха 10/35, Потери: 1.0790
Эпоха 15/35, Потери: 0.6919
Эпоха 20/35, Потери: 0.3927
Эпоха 25/35, Потери: 0.2406
Эпоха 30/35, Потери: 0.1952
Эпоха 35/35, Потери: 0.1504
Обучение завершено!



6. Примеры сгенерированных текстов для разных температур.

Начальная строка: 'Князь'

Длина генерации: 200 символов

=====Температура: 0.5 =====

Князь на теперь, когда ей столько надо было содержанием рассказа он держал так руку. Другою рукой он держал лорнет в ладони и глаза в гостиную.. Соверю кажды. Так говорила в июле 1805 года известны предост

===== Температура: 1.0 =====

Князь на наждой не смешно противоположного мнения, оглядывался на тем, доброй Эловой, и того не пущу вам, вытажавший последнеге занте може, показать вам, но Австрию! Я ничего не могут судить про то, что не

===== Температура: 1.5 =====

Князь на Василия; когда-то мой, в одном слове мадемуазель Жорж не только вошла в шент? Прождо, как бы так ласвое выв, очень глядя на ней самых людей, когда в гостиную вошла в гостиную. Я надите, сказал кня

7. Анализ качества: сравнение температур, осмысленность, грамматика.

АНАЛИЗ КАЧЕСТВА ГЕНЕРАЦИИ

Температура 0.5:

- Более детерминированный вывод
- Меньше ошибок, но может быть повторяющимся
- Хорошо для воспроизведения стиля

Температура 1.0:

- Сбалансированный режим
- Разнообразие при сохранении осмысленности
- Рекомендуется для творческих задач

Температура 1.5:

- Очень случайный вывод
- Много ошибок и нелогичных переходов
- Интересно для экспериментов, но редко полезно

8. Создание GRU и сравнение моделей LSTM и GRU.

Архитектура нейросети на основе GRU:

```
self.embedding = nn.Embedding(vocab_size, embed_size)
self.gru = nn.GRU(embed_size, hidden_size, num_layers, batch_first=True)
self.fc = nn.Linear(hidden_size, vocab_size)
```

Обучение модели GRU выполнялось аналогично LSTM:

Обучение модели GRU...

Эпоха 5/30, Потери: 1.3669

Эпоха 10/30, Потери: 0.9398


Эпоха 15/30, Потери: 0.6682

Эпоха 20/30, Потери: 0.5934

Эпоха 25/30, Потери: 0.5633

Эпоха 30/30, Потери: 0.5691

Обучение GRU завершено!



Сравнение итоговых потерь:

LSTM: 0.1504

GRU: 0.5691

9. Исследование влияния длины последовательности.

Для исследования такого влияния выполнялось обучение модели нейросети на основе LSTM с разными значениями параметра `seq_lengths = [50, 100, 200]` на 25 эпохах. Результаты обучения:

Тестирование `seq_length = 50...`


Эпоха 5/25, Потери: 1.5951
Эпоха 10/25, Потери: 1.1612
Эпоха 15/25, Потери: 0.8033
Эпоха 20/25, Потери: 0.4983
Эпоха 25/25, Потери: 0.3029

Тестирование `seq_length = 100...`

Эпоха 5/25, Потери: 1.6400
Эпоха 10/25, Потери: 1.2307
Эпоха 15/25, Потери: 0.9074
Эпоха 20/25, Потери: 0.6227
Эпоха 25/25, Потери: 0.3969

Тестирование `seq_length = 200...`

Эпоха 5/25, Потери: 1.5082
Эпоха 10/25, Потери: 1.0285
Эпоха 15/25, Потери: 0.6331
Эпоха 20/25, Потери: 0.3528
Эпоха 25/25, Потери: 0.2142



Итоговые потери при разных `seq_length`:

`seq_length = 50`: 0.3029
`seq_length = 100`: 0.3969
`seq_length = 200`: 0.2142

10. Выводы о качестве модели и возможных улучшениях

ИТОГОВЫЕ РЕЗУЛЬТАТЫ

Характеристики модели:

- Размер алфавита: 77 символов
- Длина последовательности: 100
- Размер встраивания: 128
- Скрытый размер LSTM: 256
- Количество слоёв: 2
- Количество параметров: 951,245

Качество обучения:

- Итоговые потери (LSTM): 0.1504
- Итоговые потери (GRU): 0.5691

Рекомендации:

- Для осмысленной генерации используйте $T \approx 0.8-1.0$
- Для стилизации (менее разнообразно) используйте $T \approx 0.5$
- Для экспериментов можно использовать $T > 1.2$

Общий вывод по результатам генерации текста

Модель LSTM успешно выучила основные синтаксические закономерности текстового корпуса: сгенерированные фразы грамматически оформлены, узнаваемо имитируют лексику и структуру исходного материала (упоминания персонажей, предметов быта, диалоговые формы). Однако содержательная связность на уровне фразовых единств отсутствует — текст остаётся **локально осмысленным, но глобально бессвязным**, что характерно для символьных генеративных моделей без механизмов долгосрочного планирования.