

1. Механизм внимания (DL-1.9 — Базовый)

1. **Объясните общий принцип механизма внимания (Attention)**
 - Что такое векторы запроса (Query), ключа (Key) и значения (Value)?
 - Как вычисляется оценка внимания (attention score)?
 - Что такое взвешенное среднее и как оно используется для получения выходного вектора?
2. **Что такое самовнимание (Self-Attention)?**
 - Как формируются векторы Q, K, V в случае самовнимания?
 - Почему самовнимание позволяет модели учитывать зависимости между всеми элементами последовательности?
3. **Объясните формулу масштабированного внимания (Scaled Dot-Product Attention):**

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

- Зачем выполняется деление на $\sqrt{d_k}$?
 - Какую роль играет функция softmax?
4. **Что такое многоголовое внимание (Multi-Head Attention)?**
 - Как оно устроено?
 - В чём преимущество использования нескольких голов внимания вместо одной?
 - Как объединяются выходы разных голов?
 5. **Что такое позиционное кодирование (Positional Encoding)?**
 - Зачем оно нужно в трансформере, если механизм внимания не учитывает порядок токенов?
 - Какие существуют способы позиционного кодирования? Опишите один из них (синусоидальное кодирование).
 6. **Что такое причинно-следственная маскировка (Causal / Look-ahead Masking)?**
 - Для чего она используется в декодере трансформера?
 - Как она влияет на процесс вычисления внимания?

2. Архитектура трансформера (DL-1.9 — Базовый)

7. **Опишите общую архитектуру трансформера (Encoder-Decoder).**
 - Из каких основных блоков состоит кодёр (Encoder)?
 - Из каких основных блоков состоит декодер (Decoder)?
 - Чем отличается структура кодера от структуры декодера?
8. **Что такое остаточные связи (Residual Connections) и нормализация (Layer Normalization) в трансформере?**
 - Зачем они используются?
 - В каком порядке применяются: сначала нормализация, затем слой (pre-norm) или наоборот (post-norm)?

9. **Опишите блок кодера трансформера.**

- Какие слои входят в его состав?
- Какой путь проходят входные данные внутри блока?

10. **Опишите блок декодера трансформера.**

- Какие слои входят в его состав?
- Чем отличается первый подблок внимания в декодере от второго (cross-attention)?

11. **Что такое кросс-внимание (Cross-Attention) в декодере?**

- Как формируются Q, K, V в этом слое?
 - Какую роль он выполняет в задачах типа "последовательность-в-последовательность"?
-

3. Применение трансформеров (DL-1.9 — Базовый)

12. **Что такое BERT и для каких задач он используется?**

- Какая архитектура лежит в основе BERT (только энкодер или энкодер-декодер)?
- Как выполняется предобучение BERT (MLM, NSP)?
- Что такое тонкая настройка (fine-tuning) и как она выполняется?

13. **Что такое GPT и в чём его отличие от BERT?**

- Какая архитектура лежит в основе GPT (только декодер)?
- В чём заключается авторегрессивный характер GPT?
- Приведите примеры задач, для которых используется GPT.

14. **Что такое Vision Transformer (ViT)?**

- Как изображение преобразуется в последовательность токенов для подачи в трансформер?
- Какие преимущества и недостатки у ViT по сравнению со свёрточными сетями (CNN)?

15. **Как использовать готовые модели трансформеров через библиотеку Hugging Face?**

- Что такое `transformers` library?
- Как загрузить предобученную модель (например, BERT) и выполнить инференс?
- Что такое токенизатор (tokenizer) и зачем он нужен?

16. **Какие параметры настраиваются при обучении трансформеров?**

- Как выбрать скорость обучения (learning rate) для тонкой настройки?
 - Почему для трансформеров часто используется AdamW?
 - Что такое warmup и зачем он нужен?
-

4. Математические основы и сравнение с RNN (DL-1.9 — Базовый)

17. В чём основные преимущества трансформера перед RNN/LSTM?

- Как трансформер решает проблему долгосрочных зависимостей?
- Как трансформер достигает параллелизма при обучении?

18. Как вычисляется сложность трансформера по памяти и времени?

- Почему сложность $O(T^2 \cdot d)$ является проблемой для длинных последовательностей?
- Какие существуют подходы для снижения этой сложности?

19. Что такое функция потерь при обучении трансформеров для генерации текста?

- Какой тип функции потерь используется ?